

Analiza działalności i uczenie maszynowe kliniki weterynaryjnej

Celem tego projektu było zaprojektowanie i analiza bazy danych kliniki weterynaryjnej oraz wykorzystanie technik Business Intelligence i uczenia maszynowego do wyciągania wniosków i budowania modeli predykcyjnych.


Projekt obejmuje kompletny proces analizy danych, w tym:

- projektowanie i implementacja bazy danych w SQL Server,
- analiza biznesowa w Microsoft Excel,
- tworzenie interaktywnych pulpitów nawigacyjnych w Power BI,
- eksploracyjna analiza danych w Pythonie,
- modele uczenia maszynowego do predykcji i klasyfikacji.

Projekt demonstruje praktyczne umiejętności w zakresie zarządzania danymi, raportowania, wizualizacji i analityki predykcyjnej.

Baza danych SQL Server

Relacyjna baza danych została utworzona w środowisku Microsoft SQL Server. Zawiera informacje dotyczące właścicieli zwierząt, pacjentów, lekarzy weterynarii, wizyt, zabiegów oraz recept. Do zapewnienia spójności danych wykorzystano klucze główne oraz klucze obce.



Rys. 1. Diagram relacyjnej bazy danych kliniki weterynaryjnej.

Przygotowanie danych

W celu zwiększenia liczby rekordów wykorzystano dane wygenerowane przy pomocy modelu AI Claude. Pozwoliło to uzyskać większy zbiór danych odpowiedni do analiz oraz budowy modeli uczenia maszynowego.

	treatment_id	visit_id	name	description	notes	duration	cost
1	1	1	szczepienie	podanie szczepionki przeciw wściekliźnie	Zwierzę było spokojne. Podano szczepionkę. Brak rea...	40	50.00
2	2	2	alergia	podanie leków na alergię	Wysepka zniknęła częściowo. Zalecana kontrola po tyg...	30	40.00
3	3	3	kontrola	kontrola stanu zdrowia	Zwierzę w dobrej kondycji. Brak uwag.	60	30.00
4	4	4	uraz łapy	wykonanie zdjęcia RTG łapy	Rana oczyszczona i zabandażowana. Pacjent był nies...	90	90.00
5	5	5	operacja	Przeprowadzono operację guza u chomika. Pacjent ...	NULL	120	150.00
6	6	7	diagnostyka	Standardowe badanie ogólne.	Informacja o profilaktyce.	60	15.00
7	7	9	uraz łapy	Oczyszczenie i zdezynfekowanie rany. Założenie opa...	Uraz spowodowany niefortunnym skokiem. Rana oczy...	100	110.00
8	8	10	badanie ogólne	Standardowe badanie kontrolne zwierzęcia.	Pacjent zdrowy. Zalecono kontrolę profilaktyczną za 6 ...	30	60.00
9	9	11	badanie ogólne	Ocena kondycji oraz parametrów życiowych.	Brak nieprawidłowości.	25	50.00
10	10	12	szczepienie	Podanie szczepionki przeciw wściekliźnie.	Brak reakcji poszczepiennej.	20	70.00
11	11	13	kontrola rany	Kontrola procesu gojenia oraz wymiana opatrunku.	Rana goi się prawidłowo. Zmieniono opatrunek.	35	80.00
12	12	14	kontrola ortopedyczna	Kontrola urazu łapy po wcześniejszym leczeniu.	Kulawienie minimalne. Kontynuować ograniczenie ruc...	40	90.00
13	13	15	kontrola urazu	Ocena procesu gojenia kończyny.	Stan stabilny. Opatrunek wymieniony.	35	85.00

Rys. 2. Przykładowe dane tabeli *Treatments* przechowywane w bazie SQL Server.


Analiza biznesowa w Excelu

Celem niniejszej analizy jest przedstawienie działalności kliniki weterynaryjnej na podstawie danych zgromadzonych w bazie danych. Analiza obejmuje informacje dotyczące pacjentów, wizyt, wykonanych zabiegów oraz pracy lekarzy weterynarii. Wykorzystano tabele przestawne i wykresy przygotowane w programie Microsoft Excel 2010 w celu wyznaczenia kluczowych wskaźników efektywności, identyfikacji najważniejszych źródeł przychodów oraz oceny kosztów leczenia w podziale na gatunki zwierząt i kategorie zabiegów. Przedstawione wyniki pozwalają lepiej zrozumieć strukturę działalności kliniki oraz wyciągnąć wnioski dotyczące jej funkcjonowania.

Analiza lekarzy

Lekarz	Wizyty	Całkowita suma zabiegów	Średni koszt zabiegu
Marek Nowak	31	4 175,00 zł	134,68 zł
Paweł Mazur	27	2 130,00 zł	78,89 zł
Tomasz Kaczmarek	25	3 260,00 zł	130,40 zł
Ewa Lis	25	2 170,00 zł	86,80 zł
Anna Wójcik	20	1 410,00 zł	70,50 zł
Janusz Szymański	19	1 990,00 zł	104,74 zł
Suma końcowa	147	15 135,00 zł	102,96 zł

Rys. 3. Analiza pracy lekarzy weterynarii




Rys. 4. Wykres przedstawiający przychód lekarzy.

Największą liczbę wizyt obsłużył Marek Nowak wynoszącą 31 oraz wygenerował najwyższy całkowity przychód 4175 zł, co wskazuje na największe obciążenie pracą i jednocześnie wysoką efektywność finansową. Anna Wójcik ma najniższy całkowity przychód i najniższą średnią wartość wizyty, co może oznaczać mniejsze obciążenie lub mniej skomplikowane przypadki.

Analiza gatunków

Gatunki	Średnia kosztu zabiegu	Suma z cost
chomik	112,7272727	1 240,00 zł
kot	91,82692308	4 775,00 zł
królik	191,6666667	1 150,00 zł
papuga	90	630,00 zł
pies	103,3802817	7 340,00 zł
Suma końcowa	102,9591837	15 135,00 zł

Rys. 5. Analiza kosztów zabiegów według gatunków zwierząt.



Rys. 6. Wykres - średnia kosztu zabiegu wg gatunku zwierząt.

Najwyższy średni koszt zabiegów dotyczy królików - 191,67 zł, co wskazuje na bardziej kosztowne lub specjalistyczne leczenie tej grupy.

Psy generują umiarkowany koszt w okolicach 103,38 zł, ale prawdopodobnie stanowią największą grupę pacjentów.

Koty i papugi mają podobny, niższy średni koszt w zakresie 90-92 zł, co sugeruje standardowe procedury.

Chomiki mają stosunkowo wyższy średni koszt niż koty i psy, co może wynikać z mniejszej liczby przypadków, ale bardziej specjalistycznych interwencji.

Psy wygenerowały najwyższy łączny przychód w okolicach 7340 zł, przy średnim koszcie zabiegu wynoszącym około 103,38 zł. Oznacza to, że ten gatunek prawdopodobnie stanowi najliczniejszą grupę pacjentów kliniki. Koty zajmują drugie miejsce pod względem łącznych kosztów - 4775 zł. Natomiast papugi charakteryzują się najniższą łączną wartością usług 630 zł oraz jednym z najniższych średnich kosztów zabiegu 90 zł, co wskazuje na niewielki udział tej grupy w działalności kliniki.

Podsumowując, koszt leczenia zależy bardziej od typu zwierzęcia niż od samej liczby przypadków.

Analiza konkretnych pacjentów

species	(Wszystko)	
Top pacjenci wg kosztów leczenia		
Imiona zwierząt	Całkowita suma	Ilość wizyt
Zuzia	335	3
Ptyś	1250	2
Reksio	290	2
Czesia	485	2
Puch	940	2
Kleks	360	2
Śmiga	325	2
Loki	415	2
Atlas	390	2
Pistacjo	380	2
Suma końcowa	5170	21


Rys. 7. Analiza kosztów leczenia pacjentów.

Największe łączne koszty leczenia generują pacjenci tacy jak Ptyś - 1250 zł i Puch - 940 zł, co wskazuje na bardziej złożone lub częstsze wizyty. Większość zwierząt ma dwie wizyty, co oznacza powtarzalność leczenia i kontrolny charakter opieki. Pacjent Zuzia wyróżnia się największą liczbą wizyt wynoszącą 3, co może sugerować przewlekły przypadek lub dłuższy proces leczenia. Na podstawie danych koszty są silnie skoncentrowane na kilku pacjentach.

Analiza kategorii leczenia

Liczba zabiegów wg kategorii leczenia		
Kategoria leczenia	Ilość	Całkowita suma
Badanie ogólne	18	1 075,00 zł
Chirurgia	16	4 405,00 zł
Dermatologia	24	1 705,00 zł
Diagnostyka	15	1 625,00 zł
Dieta	1	45,00 zł
Kardiologia	18	2 420,00 zł
Kontrola	11	470,00 zł
Odrobaczenie	6	205,00 zł
Ortopedia	22	2 215,00 zł
Szczepienie	16	970,00 zł
Suma końcowa	147	15 135,00 zł

Rys. 8. Analiza kosztów zabiegów.



Rys. 9. Wykres pokazujący przychód kosztów dla danej kategorii.

Największy udział w kosztach mają chirurgia, czyli przychód 4405 zł, kardiologia 2420 zł, ortopedia 2215 zł co oznacza, że dominują zabiegi specjalistyczne i wysokokosztowe. Najczęściej wykonywane są zabiegi dermatologii 24 przypadki, ortopedii 22, badania ogólne 18 i kardiologii 18. Niskokosztowe lub rzadkie procedury np. dieta, odrobaczanie mają marginalny wpływ na przychód.

Podstawowe statystyki

Tabela KPI	
Metryka	Wartość
Liczba zabiegów	147
Liczba pacjentów	78
Łączny przychód	5505
Średni koszt zabiegu	37,44897959
Najdroższy zabieg	180
Najtańszy zabieg	15
Anulowane wizyty	7

Rys. 10. Podsumowanie najważniejszych wskaźników działalności.


Dashboard Power BI

W celu stworzenia interaktywnego raportu wykorzystano Power BI. Dashboard został podzielony na trzy główne sekcje:

- Podsumowanie

Pytania biznesowe

- Jaki jest całkowity przychód kliniki?
- Ile zabiegów zostało wykonanych?
- Jaki jest średni koszt pojedynczego zabiegu?
- Jaki odsetek wizyt został anulowany?
- Który typ zabiegu generuje najwyższe dochody?
- Jak efektywnie funkcjonuje klinika jako całość?




Rys. 11. Widok sekcji Podsumowanie.

• Pacjenci i leczenie

Sekcja prezentuje następujące pytania:

- Które gatunki zwierząt najczęściej korzystają z usług kliniki?
- Które gatunki generują najwyższe przychody?
- Jakie kategorie leczenia są wykonywane najczęściej?
- Które zabiegi są najbardziej dochodowe dla konkretnego gatunku?
- Jaki jest średni koszt leczenia dla poszczególnych gatunków?
- Czy istnieją gatunki wymagające bardziej kosztownego leczenia?




Rys. 12. Widok sekcji Pacjenci i leczenie.

- Lekarze

Sekcja umożliwi ocenę efektywności pracy lekarzy weterynarii.

Pytania:

- Który lekarz obsługuje największą liczbę wizyt?
- Który lekarz generuje najwyższe przychody?
- Jaka jest średnia wartość zabiegów wykonywanych przez poszczególnych lekarzy?
- Czy istnieją znaczące różnice w efektywności lekarzy?
- Którzy lekarze specjalizują się w bardziej kosztownych zabiegach?
- Jak rozkłada się obciążenie pracą pomiędzy lekarzami?
- Czy liczba wykonanych zabiegów przekłada się na generowany przychód?



Rys. 13. Widok sekcji Lekarze.

Analiza danych w Python

W Pythonie połączono dane z wielu tabel SQL w jeden zbiór analityczny, który następnie wykorzystano do przeprowadzenia analizy eksploracyjnej.

Zakres analizy obejmował: statystyki opisowe, analizę kosztów zabiegów, czasu trwania zabiegów, gatunków zwierząt, analizę statusów wizyt, analizę korelacji pomiędzy zmiennymi.

Przykładowe wnioski

Gatunki zwierząt

	count	sum	mean
species			
pies	71	7340.0	103.380282
kot	52	4775.0	91.826923
chomik	11	1240.0	112.727273
królik	6	1150.0	191.666667
papuga	7	630.0	90.000000

Rys. 14. Widok ukazujący gatunki zwierząt wraz ze statystykami.

Które gatunki zwierząt korzystają z usług kliniki najczęściej i generują największe przychody?

Pozwala określić strukturę pacjentów kliniki oraz zidentyfikować gatunki, które mają największy wpływ na przychody placówki.


Analiza lekarzy

	count	sum	mean
vet_fullName			
Marek Nowak	31	4175.0	134.677419
Tomasz Kaczmarek	25	3260.0	130.400000
Ewa Lis	25	2170.0	86.800000
Paweł Mazur	27	2130.0	78.888889
Janusz Szymański	19	1990.0	104.736842
Anna Wójcik	20	1410.0	70.500000

Rys. 15. Analiza lekarzy ze statystykami.

Którzy lekarze generują najwyższe przychody i obsługują największą liczbę wizyt? Analiza umożliwia ocenę efektywności pracy lekarzy weterynarii oraz porównanie ich wyników pod względem liczby wykonanych zabiegów i wygenerowanych przychodów.

Trend przychodów w czasie




Rys. 16. Przychód dla każdego miesiąca.

Jak zmieniają się przychody kliniki w kolejnych miesiącach?

Analiza pozwala wykryć sezonowość oraz okresy zwiększonego lub zmniejszonego zapotrzebowania na usługi weterynaryjne.

Czas zabiegu według gatunku i miesiący



Rys. 17. Wykresy ukazujące czas dla gatunków i miesięcy.

Czy czas trwania zabiegów różni się pomiędzy gatunkami zwierząt lub miesiący?


Procent zabiegów zakończonych receptą

	name_y	liczba_recept	liczba_zabiegów	procent_recept
0	alergia	1	2	50.000000
1	badanie ogólne	8	20	40.000000
2	chirurgia	7	17	41.176471
3	dermatologia	9	26	34.615385
4	diagnostyka	2	15	13.333333
5	dieta	0	1	0.000000
6	kardiologia	3	19	15.789474
7	kontrola	5	13	38.461538
8	kontrola ortopedyczna	0	1	0.000000
9	kontrola pooperacyjna	1	1	100.000000
10	kontrola rany	2	2	100.000000
11	kontrola urazu	0	1	0.000000
12	odrobaczanie	3	7	42.857143
13	operacja	2	2	100.000000
14	ortopedia	7	20	35.000000
15	szczepienie	7	20	35.000000
16	uraz łapy	3	3	100.000000

Rys. 18. Kategoria zabiegów pokazująca liczbę zabiegów, recept wraz udziałem procentowym wypisanych recept.

Które rodzaje leczenia najczęściej wymagają wystawienia recepty?


Zależność czasu zabiegu i kosztu



Rys. 19. Wykres prezentujący czas zabiegu a koszt.

Czy dłuższe zabiegi wiążą się z wyższymi kosztami leczenia?

Analiza umożliwia ocenę zależności pomiędzy czasem trwania zabiegu a jego kosztem. Jest to jedna z najważniejszych analiz, ponieważ stanowi podstawę późniejszego modelowania predykcyjnego.



Rys. 20. Wykres korelacji czasu zabiegu a kosztem.

Wartość współczynnika korelacji na poziomie 0.83 świadczy o silnym związku liniowym pomiędzy zmiennymi. Zależność ta potwierdza obserwacje z wykresu rozrzutu oraz uzasadnia wykorzystanie zmiennej *duration* jako jednej z kluczowych cech w modelach predykcyjnych służących do prognozowania kosztu zabiegu.

Uczenie maszynowe

Zadanie regresji

Pierwszym zadaniem było przewidywanie kosztu zabiegu na podstawie cech pacjenta oraz informacji o leczeniu.

Zmienna docelowa: *cost*

Zmienne objaśniające: *duration, species, gender*

Przetestowane modele:

- Linear Regression
- Random Forest Regressor i strojenie parametrów
- XGBoost Regressor i strojenie parametrów

Wyniki

Algorytm	R ²	MAE
Linear Regression	0.664	29.07
Random Forest	0.437	27.40
Random Forest - strojenie parametrów	0.472	26.51
XGBoost	0.264	29.88
XGBoost - strojenie parametrów	0.406	28.38

Model regresji liniowej osiągnął najwyższą wartość współczynnika determinacji $R^2 = 0.664$, co oznacza, że wyjaśnia około 66.4% zmienności kosztów

zabiegów. Świadczy to o stosunkowo silnej zależności liniowej pomiędzy wykorzystanymi cechami a kosztem zabiegu.

Model Random Forest uzyskał niższy współczynnik R^2 0.473, jednak osiągnął najniższy średni błąd bezwzględny - MAE = 26.52 zł. Oznacza to, że przeciętna różnica między wartością rzeczywistą a przewidywaną była najmniejsza spośród wszystkich testowanych modeli.

Model XGBoost osiągnął najniższą skuteczność predykcijną wynoszącą R^2 = 0.406 oraz wyższy błąd niż Random Forest. W analizowanym zbiorze danych bardziej zaawansowany model boostingowy nie przyniósł poprawy jakości predykcji.

	Rzeczywisty koszt	Przewidywany koszt	Błąd bezwzględny
132	230.0	135.705549	94.294451
53	70.0	43.356678	26.643322
145	50.0	31.264846	18.735154
21	50.0	31.264846	18.735154
111	65.0	66.443896	1.443896
14	85.0	89.531113	4.531113
83	110.0	77.439281	32.560719
33	40.0	14.726730	25.273270
88	110.0	135.705549	25.705549

Rys. 21. Porównanie rzeczywistych i przewidywanych kosztów zabiegów regresji liniowej.

Zadanie klasyfikacji

Drugim zadaniem była klasyfikacja zabiegów na:

- zabiegi niekosztowne (0),
- zabiegi kosztowne (1).

Za kosztowny uznano zabieg, którego koszt przekraczał 100 zł.

Utworzenie zmiennej docelowej: *high_cost*

Zmienne objaśniające: *duration*, *species*, *gender*

Proporcja klas dla kolumny high_cost.

proportion	
high_cost	
0	77.55102
1	22.44898

Rys. 22. Proporcja klas


Przetestowane modele:

- Logistic Regression i strojenie parametrów
- Random Forest Classifier i strojenie parametrów

Wyniki

Algorytm	Accuracy	Precision	Recall	F1 score
Logistic Regression	0.867	0.866	0.866	0.866
Logistic Regression - strojenie parametrów	0.833	0.842	0.833	0.838
Random Forest	0.833	0.827	0.833	0.829
Random Forest - strojenie parametrów	0.833	0.842	0.833	0.838


Najlepsze wyniki osiągnęła regresja logistyczna bez strojenia, uzyskując Accuracy oraz F1-score na poziomie 86.7%. Model Random Forest po strojeniu hiperparametrów nie poprawił dokładności modelu, jednak poprawie uległa zdolność wykrywania kosztownych zabiegów, F1-score z 0.829 do 0.837. Ostatecznie za najlepszy model klasyfikacyjny uznano regresję logistyczną ze względu na najwyższą skuteczność oraz prostotę interpretacji wyników.



Rys. 23. Macierz pomyłek modelu klasyfikacyjnego regresji logistycznej bez parametrów.

- 21 zostało poprawnie wykrytych tanich zabiegów
- 5 poprawnie wykrytych drogich zabiegów
- 2 tanie zabiegi uznano błędnie za drogie
- 2 drogie zabiegi uznano błędnie za tanie

ROC, AUC - regresja logistyczna



Rys. 24. Krzywa ROC dla modelu regresji logistycznej.

Uzyskana wartość AUC wyniosła 0.929, co świadczy o bardzo dobrej zdolności modelu do rozróżniania kosztownych i nie kosztownych zabiegów. Krzywa

ROC przebiega blisko lewego górnego rogu wykresu, co oznacza wysoką skuteczność wykrywania kosztownych zabiegów przy jednoczesnym utrzymaniu niskiej liczby błędnych klasyfikacji.

Weryfikacja rzeczywistych i przewidywanych klas zabiegów z dodatkowymi informacjami

	pet_name	treatment_name	species	duration	cost	Rzeczywista klasa	Przewidywana klasa
95	Wróbel	dermatologia	pies	25.0	50.0	0	0
117	Rex	diagnostyka	pies	35.0	95.0	0	0
152	Rufi	badanie ogólne	pies	20.0	50.0	0	0
145	Bajka	dermatologia	pies	25.0	50.0	0	0
33	Ruda	kontrola	kot	20.0	40.0	0	0
140	Baśka	badanie ogólne	pies	30.0	60.0	0	0
20	Śnieżka	badanie ogólne	królik	30.0	60.0	0	0
79	Fado	kardiologia	pies	35.0	110.0	1	0

Rys. 25. Porównanie rzeczywistych i przewidywanych klas zabiegów.

Predykcja dla nowych, niewidzianych wcześniej rekordów

Drogi zabieg

- duration: 90
- species: pies
- gender: samiec

Przewidywana klasa: 1
Prawdopodobieństwo drogiego zabiegu: 99.99%

Rys. 26. Przykładowa predykcja dla nowego rekordu.

Dodatkowe eksperymenty

Przeprowadzono również:

- balansowanie klas metodą SMOTE,
- analizę ważności cech.

Podsumowanie i wnioski

Projekt pozwolił przeprowadzić kompletny proces analityczny, od zaprojektowania relacyjnej bazy danych, przez analizę biznesową i wizualizację danych, aż po budowę modeli uczenia maszynowego.

Najważniejsze wnioski:

- czas trwania zabiegu jest silnie związany z jego kosztem,

- psy wygenerowały najwyższy całkowity przychód,
- chirurgia była najbardziej dochodową kategorią leczenia,
- model regresji logistycznej osiągnął bardzo dobre wyniki klasyfikacji, Accuracy = 86.7%, AUC = 0.929,
- modele uczenia maszynowego mogą wspomagać szacowanie kosztów oraz klasyfikację planowanych zabiegów.

Projekt pokazuje praktyczne zastosowanie technologii SQL Server, Excel, Power BI oraz Python w procesie analizy danych i wspomagania decyzji biznesowych.